

# KREDİ TAHMİN ANALİZİ

MAKİNE ÖĞRENİM ALGORİTMALARININ KARŞILAŞTIRILMASI

HAZIRLAYANLAR:

Mehmet Karabulut

Muhammet Enes Akyüz

Ömer Ömer

Abdu Khalek Aktaa



# İçerik

- Projenin Amacı ve Problem Tanımı
- Veri Setinin Tanıtımı
- Veri Ön İşleme Adımları
- Kullanılan Makine Öğrenmesi Algoritmaları
- Karar Ağacı (Denetimli Öğrenme)
- K-Means (Denetimsiz Öğrenme)
- Yapay Sinir Ağı – ANN (Derin Öğrenme)
- Random Forest (Rastgele Öğrenme)
- Algoritmaların Karşılaştırılması
- Sonuç ve Değerlendirme



# VERİ SETİ TANITIMI

---

- Bu projede kullanılan veri seti, banka müşterilerinin kredi başvurularına ait bilgileri içermektedir
- Her bir satır, bir müşteriye temsil etmektedir
- Sütunlar ise müşterinin finansal ve demografik özelliklerinden oluşmaktadır
- Veri seti kaggleden alınmıştır.
- Biz bu sunumda veri setinin yapısını, kullanılan algoritmaları ve elde edilen sonuçların anlamını açıklıyoruz



# VERİ SETİ ÖZELLİKLERİ

---

- Veri seti sınıflandırma problemi için uygundur
- Girdi değişkenleri (örnek):
  - Yaş: Müşterinin yaşı
  - Aylık gelir: Müşterinin düzenli geliri
  - Borç durumu: Müşterinin mevcut borç bilgisi
  - Kredi geçmişi: Daha önceki kredi ödeme durumu
- Hedef değişken:
  - Kredi onayı (Evet / Hayır)
- Amaç, bu özellikleri kullanarak müşterinin kredi alıp alamayacağını tahmin etmektir



# VERİ ÖN İŞLEME ADIMLARI

---


- Modelleme aşamasından önce veri seti ön işleme sürecinden geçirilmiştir
- Gerçekleştirilen temel ön işleme adımları:
  - Eksik verilerin kontrol edilmesi ve gerekli durumlarda giderilmesi
  - Sözel değişkenlerin sayısal forma dönüştürülmesi (encoding)
  - Sayısal değişkenlerin ölçeklendirilmesi (normalizasyon / standardizasyon)
  - Veri setinin eğitim (train) ve test (test) olarak ayrılması





# KORELASYON ANALIZI

- Modelleme öncesinde değişkenler arasındaki ilişkiler incelenmiştir
- Yüksek korelasyona sahip değişkenler model performansını olumlu etkileyebilir
- Düşük veya anlamsız korelasyona sahip değişkenler modelden çıkarılabilir
- Bu analiz sayesinde veri seti daha iyi anlaşılmıştır



# KULLANILAN ALGORİTMALAR

---


- Karar Ağacı (Denetimli Öğrenme)
- K-Means (Denetimsiz Öğrenme)
- Yapay Sinir Ağı – ANN (Derin Öğrenme)
- Random Forest (Rastgele Öğrenme)





# DENETİMLİ ÖĞRENME: KARAR AĞACI


- Karar ağacı, etiketli verilerle çalışan denetimli bir öğrenme algoritmasıdır
- Bu projede giriş değişkenleri kullanılarak müşterinin kredi onayı alıp alamayacağı tahmin edilmiştir
- Algoritma, veriyi karar kurallarına göre dallara ayırır
- Her bölünmede en iyi sonucu veren özellik seçilir
- Bölme işlemi sırasında Gini Index, Entropi ve Bilgi Kazanımı gibi ölçütler kullanılır
- Sonuç olarak yorumlanabilir bir ağaç yapısı elde edilir






# HANGI BILGI DAHA ÖNEMLİ?

---




# DENETİMSİZ ÖĞRENME: K-MEANS

- K-Means algoritması, etiket bilgisi olmadan çalışan bir denetimsiz öğrenme yöntemidir
- Bu projede kredi onayı bilgisi dikkate alınmadan müşteriler benzerliklerine göre gruplandırılmıştır
- Amaç, müşterilerin finansal özelliklerine göre doğal segmentlerini keşfetmektir
- Algoritma şu adımlarla çalışır:
  - a.K adet küme merkezi rastgele belirlenir
  - b.Her müşteri en yakın merkeze atanır
  - c.Küme merkezleri güncellenir ve işlem tekrar edilir
- Elde edilen kümeler, müşteri profillerinin analiz edilmesini sağlar



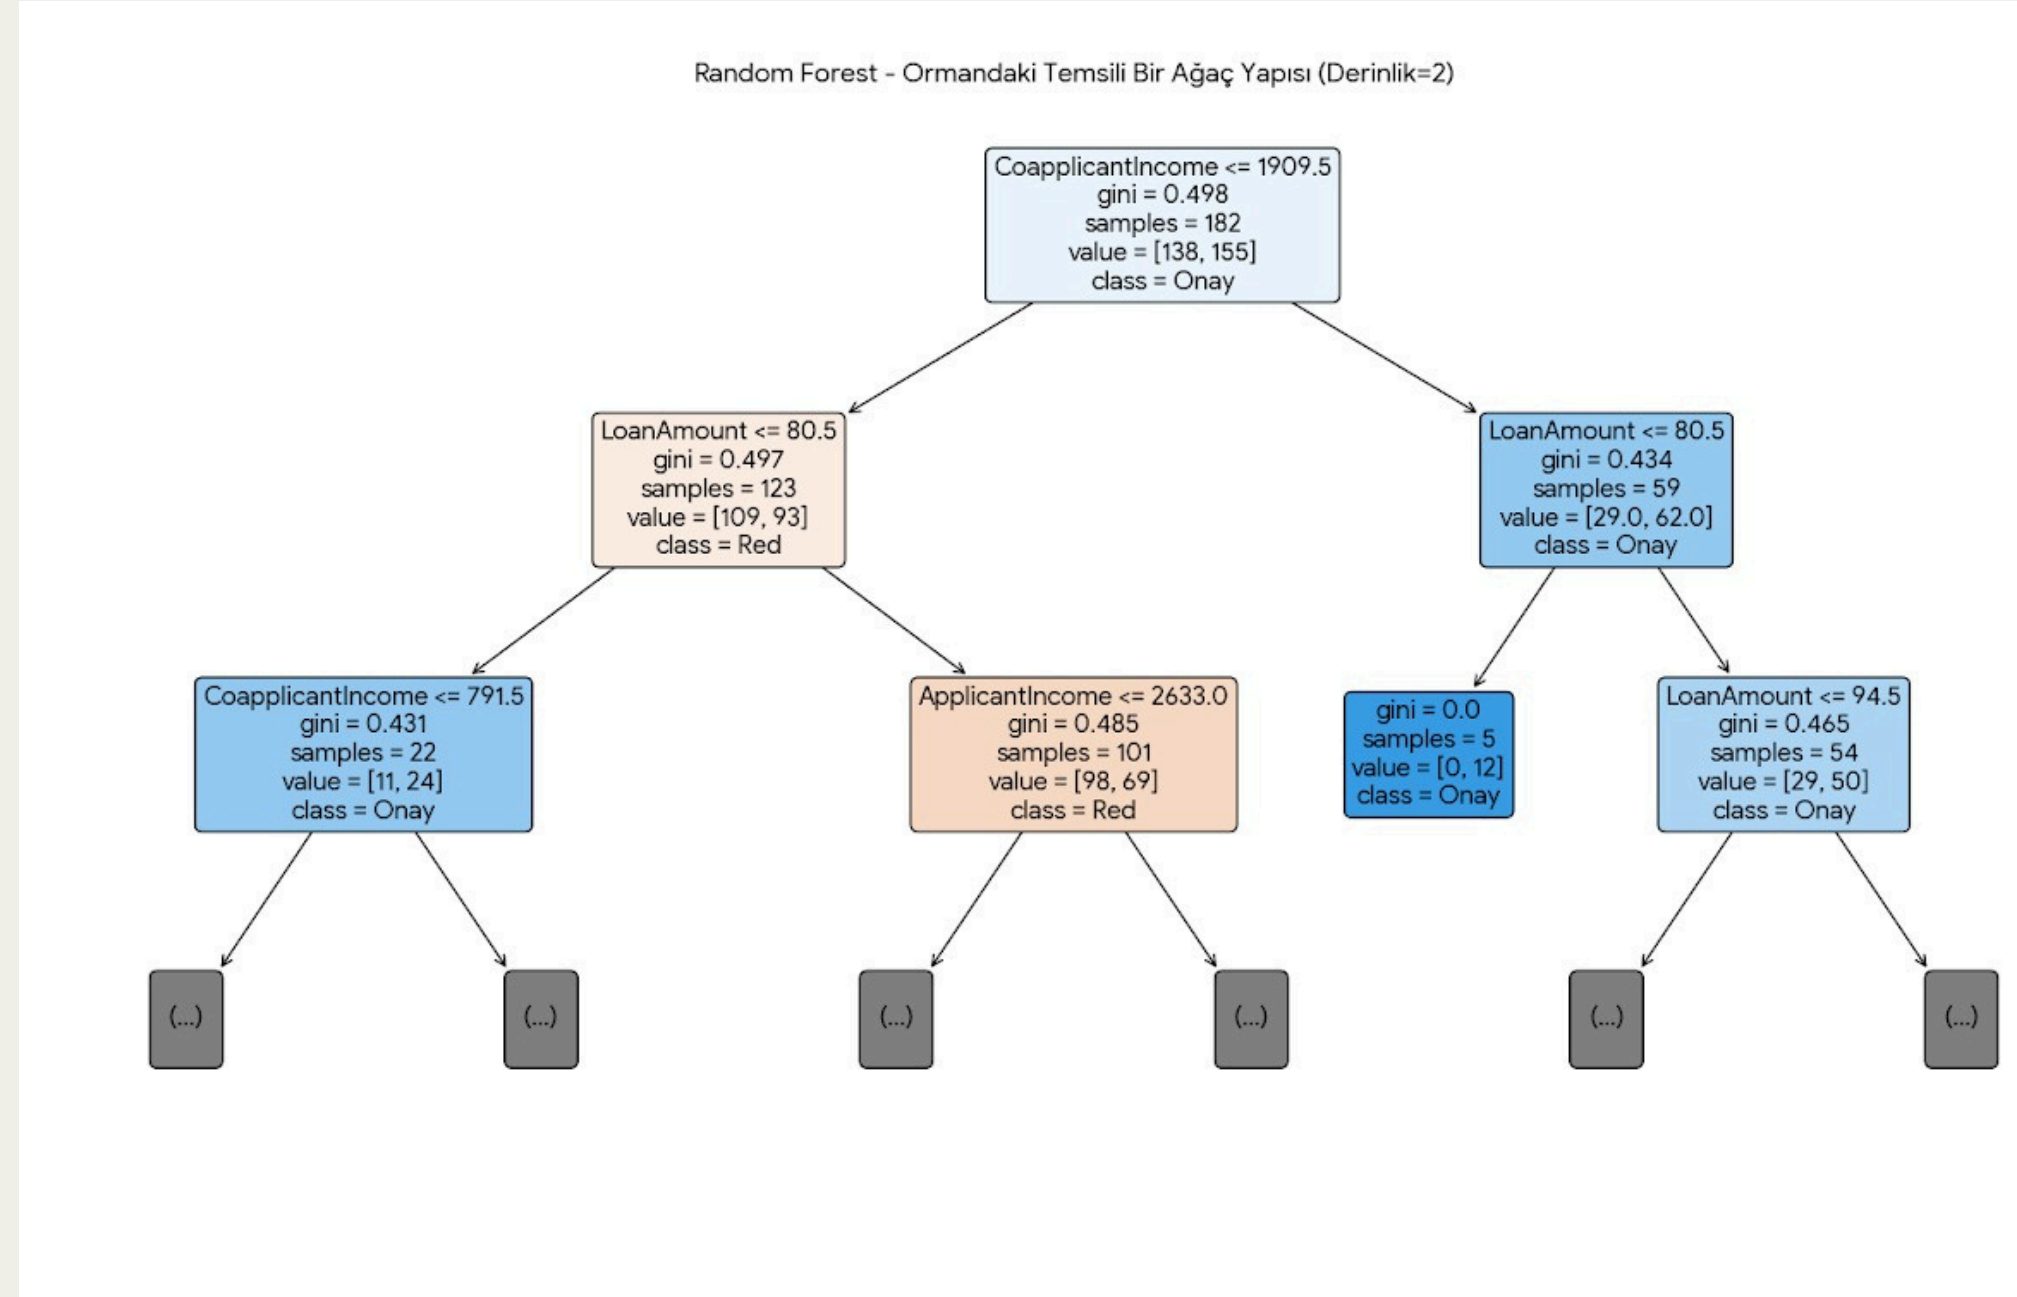
# DERİN ÖĞRENME: YAPAY SINIR AĞI (ANN)

- Yapay sinir ağları, insan beynindeki nöronların çalışma mantığından esinlenmiştir
- Bu projede, müşteri özellikleri giriş olarak verilmiş ve kredi onayı sonucu tahmin edilmiştir
- Ağ yapısı üç ana bölümden oluşur:
  - Giriş katmanı: Yaş, gelir, borç gibi özellikler
  - Gizli katmanlar: Veriler arasındaki karmaşık ilişkileri öğrenir
  - Çıkış katmanı: Kredi onayı sonucu üretir
- Model, hatayı azaltmak için geri yayılım yöntemi ile eğitilmiştir




# RASTGELE ÖĞRENME: RANDOM FOREST

- Her ağaç, veri setinin ve özelliklerin rastgele seçilmiş alt kümeleri ile eğitilir
- Bu sayede tek bir karar ağacına göre daha genellenebilir bir model elde edilir
- Bu projede Random Forest algoritması kredi onayı tahmini için kullanılmıştır
- Nihai karar, tüm ağaçların sonuçlarının oylanmasıyla belirlenmiştir



# HANGİSİ DAHA ÖNEMLİ?(RANDOM FOREST)





# HATA MATRİSLERİ (CONFUSION MATRIX)

---


- Hata matrisi, sınıflandırma modellerinin performansını karşılaştırır.
- Gerçek ve tahmin edilen sınıflar karşılaştırılır
- Matriste yer alan kavramlar:
  1. True Positive (TP): Doğru tahmin edilen olumlu sınıf
  2. True Negative (TN): Doğru tahmin edilen olumsuz sınıf
  3. False Positive (FP): Yanlış olumlu tahmin
  4. False Negative (FN): Yanlış olumsuz tahmin






# KARAR AĞAÇLARI HATA MATRİSİ

- Model, test veri setindeki tüm örnekleri %100 doğrulukla sınıflandırmıştır.
- 0 (Negatif): 19 örneğin tamamı doğru tahmin edildi.
- 1 (Pozitif): 55 örneğin tamamı doğru tahmin edildi.
- Hiçbir yanlış pozitif veya yanlış negatif hata yapılmamıştır. Model veriyi mükemmel bir şekilde öğrenmiştir.




# RANDOM FOREST HATA MATRİSİ

- Model, test veri setindeki tüm örnekleri %100 doğrulukla sınıflandırmıştır.
- 0 (Negatif): 19 örneğin tamamı doğru tahmin edildi.
- 1 (Pozitif): 55 örneğin tamamı doğru tahmin edildi.
- Hiçbir yanlış pozitif veya yanlış negatif hata yapılmamıştır. Model veriyi mükemmel bir şekilde öğrenmiştir.




# YAPAY SINIR AĞI HATA MATRİSİ

- Yapay Sinir Ağı modeli oldukça yüksek bir performans sergilemiş, sadece 1 adet hata yapmıştır.
- Gerçek değeri 0 olan bir örnek, model tarafından hatalı olarak 1 olarak tahmin edilmiştir (Yanlış Pozitif).
- Gerçek değeri 1 olan 55 örneğin tamamı ise hatasız bilinmiştir.
- Modelin Precision (Kesinlik) değeri, bu tek hatadan dolayı Decision Tree'ye göre çok küçük bir farkla düşüktür ancak genel başarısı çok yüksektir.
- Doğruluk oranı 0.986486.




# K - M E A N S H A T A M A T R I S I

- Diğer modellere kıyasla en düşük performansı sergileyen modeldir.
- Gerçek değeri 0 olan 19 örneğin 9 tanesini yanlış tahmin etmiştir.
- Gerçek değeri 1 olan 55 örneğin 18 tanesini yanlış tahmin etmiştir.
- K-Means bir gözetimsiz öğrenme (clustering) algoritması olduğu için, sınıflandırma görevlerinde (classification) Decision Tree veya ANN gibi gözetimli modeller kadar keskin sonuçlar vermemesi beklenen bir durumdur.
- Doğruluk oranı 0.634135




# ROC EĞRİSİ

- Modellerin sınıflandırma eşiklerine göre performansını gösterir.
- Decision Tree ve Random Forest çizgileri sol üst köşeye tam yapıştığı için en ideal performansı sergiliyor ( $AUC = 1.00$ ).
- ANN çok yakın bir eğri çizerek ikinci sırada yer alıyor.
- K-Means eğrisi, köşegen (rastgele tahmin) çizgisine en yakın olanıdır ve performansı diğerlerinin gerisindedir.





# ALGORİTMALARIN KARŞILAŞTIRILMASI



|   | Model         | Accuracy | Precision | Recall   | F1       | ROC-AUC  | R2        |
|---|---------------|----------|-----------|----------|----------|----------|-----------|
| 0 | Decision Tree | 1.000000 | 1.000000  | 1.000000 | 1.000000 | 1.000000 | 1.000000  |
| 1 | Random Forest | 1.000000 | 1.000000  | 1.000000 | 1.000000 | 1.000000 | 1.000000  |
| 2 | ANN           | 0.986486 | 0.982143  | 1.000000 | 0.990991 | 1.000000 | 0.929187  |
| 3 | K-Means       | 0.635135 | 0.804348  | 0.672727 | 0.732673 | 0.599522 | -0.911962 |



# SONUÇ VE DEĞERLENDİRME

---

- Aynı veri seti üzerinde farklı makine öğrenmesi yaklaşımları uygulanmıştır
- Karar ağacı, yorumlanabilirliği sayesinde karar sürecini açıkça göstermiştir
- K-Means algoritması, müşteri segmentlerini ortaya çıkarmıştır
- Yapay sinir ağı, daha karmaşık ilişkileri öğrenme kapasitesine sahiptir
- Random Forest, daha dengeli ve güçlü tahminler üretmiştir
- Sonuç olarak algoritma seçiminin probleme ve veri yapısına bağlı olduğu görülmüştür

---

**BIZI DINLEDİĞİNİZ İÇİN  
TEŞEKKÜRLER**

